FIUBA · CEIA · 1B 2026

High-Volume For-Hire Services NYC

Análisis Exploratorio de Datos · Diciembre 2024

21M+	24	80/20	7
viajes	variables	split	features

Grupo #8 Gabriela Di Grazia & Byron Garcia

Dataset & Problema de ML

HVFHS Diciembre 2024

- 21,068,851 viajes registrados
- 24 variables por viaje
- Formato Parquet (459MB vs ~1.8GB en CSV)
- Fuente: TLC New York City
- Empresas: Uber (75.6%) y Lyft (24.4%)

Tipos de variables:

- **Datetime:** pickup, dropoff, request
- **Numéricas continuas:** tarifa, distancia, propina...
- **Numéricas discretas:** trip_time, zonas (categóricas!)
- **Categóricas:** empresa, flags Y/N

Problema de ML Supervisado

Regresión Supervisada

Variable Target:

driver_pay_log

¿Por qué driver_pay?

- Mayor interés comercial — optimizar asignación
- Relación causal con distancia, tiempo y tarifa
- Variabilidad suficiente para el modelo
- Log aplicado: distribución asimétrica ⟶ normal

Visualizaciones & Hallazgos del EDA

Distribución por empresa

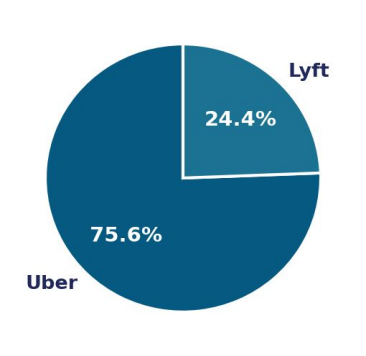

Top 10 zonas con más viajes

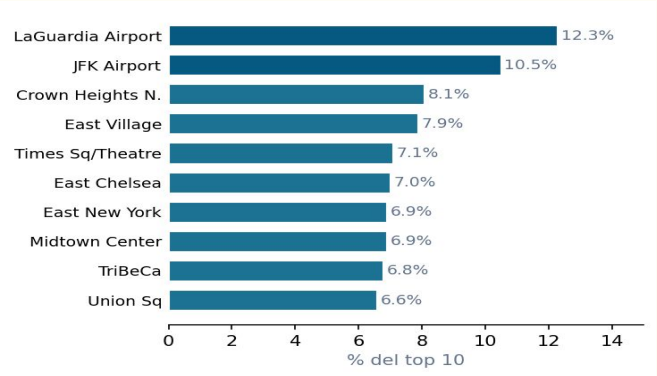

Correlación Spearman

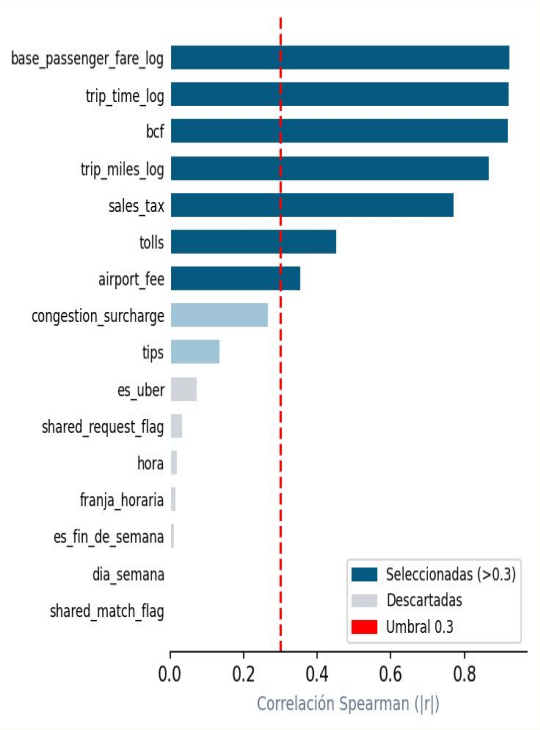

Outliers detectados con IQR

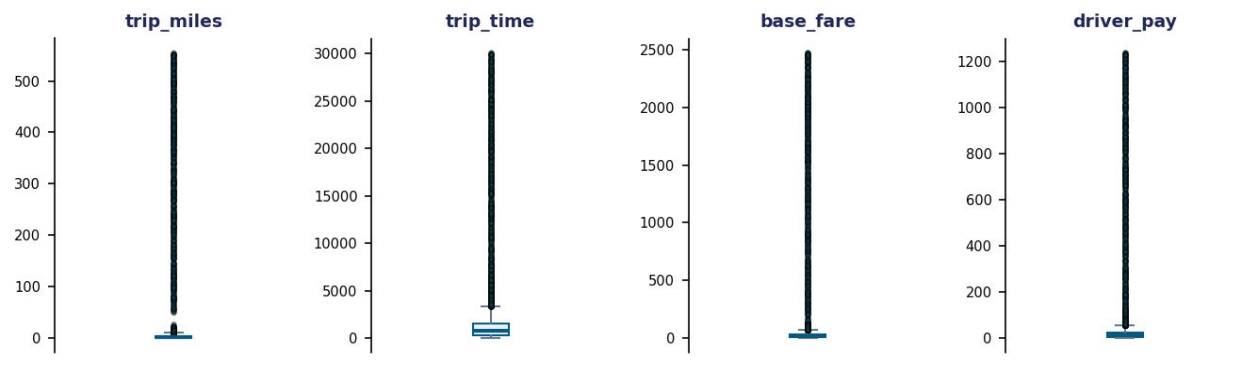

Pipeline de Preprocesamiento

1 Split 80/20

Antes de cualquier transformación para evitar data leakage. random_state=42 garantiza reproducibilidad.

2 Limpieza básica

Eliminamos trip_miles=0, trip_time=0, tarifas negativas. Ceros en tips/tolls se conservan.

3 Transformación Log

Aplicada a trip_miles, trip_time, base_passenger_fare, driver_pay. Comprime extremos reales.

4 Feature Engineering

Extracción de hora, dia_semana, franja_horaria. Encoding binario para Uber/Lyft y flags Y/N.

5 Selección — Spearman

Umbral 0.3 — brecha natural entre airport_fee y congestion_surcharge. 7 features seleccionadas.

6 Estandarización Z-score

StandardScaler sobre train. transform() en test. Evita data leakage.

Resultados & Conclusiones

7

Features finales

de 19 originales

0.3

Umbral Spearman

brecha natural

34K

Registros eliminados

solo 0.2% del train

Top features — Correlación Spearman:

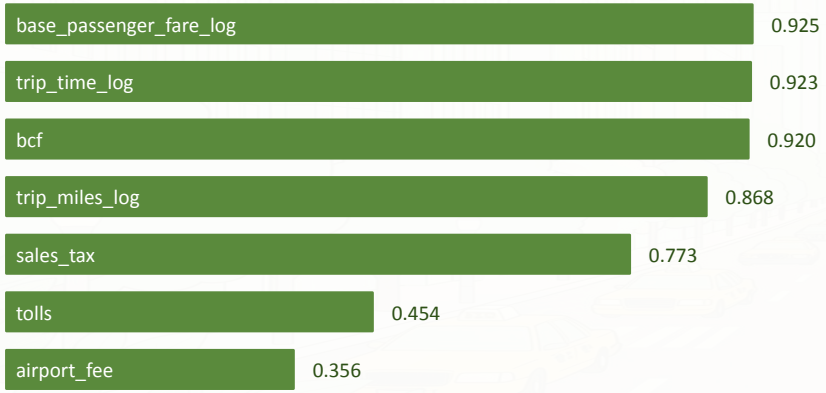

https://github.com/bamazonai/G8-TP-AnD.git

Conclusión

- El pago depende de la tarifa base y el tiempo de viaje
- Spearman fue clave por los ceros legítimos en tolls, tips y airport_fee
- La transformación log normalizó distribuciones asimétricas
- Umbral 0.3 surgió de una brecha natural en los datos